

Yesterday 5:25 PM

resume et garge le maximum de detail :ChatGPT

Oui, donc...

pondération sur internet euh... pour avoir euh... les  
meilleures sources ensemble et après un beau modèle qui  
fait la synthèse de tout sur le

D'accord.

... pièce que j'ai fait et euh... sur internet

Donc toi, ce que tu veux, c'est

avec quarante

que chaque modèle sorte...

diff... quarante-dix... sources et autres

Oui.

quarante... dix-sept sources quarante le non hallucination,  
quarante dix-sept schémas

D'accord. Donc en fait, ce que tu veux, c'est que chaque  
modèle sorte sa lecture, puis une méta-synthèse qui met  
en commun les points solides, qui gèrent les  
contradictions et qui cite des sources. C'est ça ?

Ouai

Et t'as déjà une

j'ai pas entendu

Oui, donc en fait, ce que tu veux, c'est que chaque modèle  
sorte sa lecture, puis que ça fasse une méta-synthèse qui  
met en commun les points solides, gèrent les  
contradictions et qui citent les sources ? C'est ça que tu  
veux. Oui.

Exactement c'est exactement ça ça sera l'attente euh...  
Aurag, en priorité

D'accord.

Il va y avoir une source fiable ensuite t'as... t'as... ça  
enrichit entre les quatre modèles qui ont euh... deux  
penses différents

Oui. D'accord, donc Oracle en priorité.

un petit peu différents qui vont... et... et euh... les... ils ont des... températures relativement faibles pour éviter d'halluciner donc ils sont plus

D'accord.

... euh... que créatifs

Oui.

donc pas d'hallucination Et en plus il y a l'enrichissement avec euh... le réel euh... du web Donc imaginons euh... Tiens, c'est quoi la coupe de blues de coupe du monde en 2026

Oui. Oui...

Je regarde.

Oui,

c'est compliqué

oui.

c'est compliqué parce que euh... tu vas me faire chambouler un petit peu mes... tous mes

C'est vrai. Mais...

Tu veux formaliser une architecture de réponse **multi-modèles, multi-sources et anti-hallucination**, avec une priorité donnée au RAG.

Edit

## Résumé détaillé

L'objectif est de construire un système capable de produire une réponse de haute qualité en combinant plusieurs niveaux d'analyse et plusieurs sources d'information.

### 1. Priorité au RAG

Le système doit d'abord interroger le **RAG**, car il contient les documents, données ou connaissances de référence déjà sélectionnés et considérés comme fiables.

Le RAG constitue donc la source prioritaire et le socle factuel de la réponse.

L'ordre général serait :

1. Recherche dans le RAG.
2. Identification des passages les plus pertinents.
3. Analyse de ces passages par plusieurs modèles.
4. Enrichissement éventuel avec des sources internet.
5. Synthèse finale par un modèle spécialisé.

### 2. Utilisation de plusieurs modèles

Quatre modèles différents peuvent analyser la même demande et les mêmes sources.

Chaque modèle fournit :

- sa compréhension du sujet ;
- son interprétation des documents ;
- les faits qu'il considère comme importants ;
- les éventuelles contradictions détectées ;
- son niveau de confiance ;
- les sources ou passages utilisés ;
- éventuellement des schémas, structures ou représentations différentes.

L'intérêt est que les modèles peuvent avoir des raisonnements, des formulations ou des perspectives légèrement différents.

Cette diversité permet d'enrichir l'analyse sans dépendre d'un seul modèle.

### **3. Température faible et priorité à la précision**

Les modèles doivent utiliser une température relativement basse.

Ils doivent être davantage orientés vers :

- la précision ;
- la stabilité ;
- la fidélité aux sources ;
- la cohérence ;
- la vérification des faits ;

plutôt que vers la créativité.

L'objectif est de réduire au maximum les inventions et les hallucinations.

Les modèles ne doivent pas produire une information comme certaine lorsqu'elle n'est pas présente dans les sources disponibles.

### **4. Enrichissement par le web**

Après la recherche dans le RAG, le système peut compléter l'analyse avec des recherches internet.

Le web sert notamment lorsque :

- l'information n'existe pas dans le RAG ;
- le sujet nécessite une donnée récente ;
- une information doit être vérifiée ;
- plusieurs sources doivent être comparées ;
- le système détecte un doute ou une contradiction ;
- la question porte sur un événement actuel, par exemple la Coupe du monde 2026.

Le web ne remplace pas automatiquement le RAG : il vient l'enrichir.

Les sources internet doivent être évaluées et pondérées afin de privilégier les sources les plus fiables.

## 5. Pondération des sources

Toutes les sources ne doivent pas avoir la même importance.

Le système pourrait leur attribuer un poids selon différents critères :

- fiabilité du domaine ;
- autorité de l'auteur ou de l'organisme ;
- date de publication ;
- proximité avec la source primaire ;
- cohérence avec les autres sources ;
- présence de preuves ;
- niveau de précision ;
- réputation de la source ;
- actualité de l'information ;
- correspondance avec le sujet demandé.

Une source officielle ou primaire devrait avoir davantage de poids qu'un article non sourcé ou qu'un contenu d'opinion.

## 6. Méta-synthèse finale

Après les analyses des différents modèles, un modèle final réalise une **méta-synthèse**.

Ce modèle ne doit pas simplement juxtaposer les réponses.

Il doit :

- comparer les analyses ;
- identifier les points communs ;
- isoler les éléments solides ;
- détecter les désaccords ;
- vérifier les affirmations avec les sources ;
- hiérarchiser les informations ;
- éliminer les répétitions ;
- signaler les incertitudes ;
- citer les sources ;
- produire une réponse claire et structurée.

La synthèse finale doit donc représenter ce qui résiste le mieux à la comparaison entre les modèles et les sources.

## 7. Gestion des contradictions

Lorsque deux modèles ou deux sources se contredisent, le système ne doit pas choisir arbitrairement.

Il doit examiner :

- la qualité de chaque source ;
- sa date ;
- son caractère primaire ou secondaire ;
- la précision de l'affirmation ;
- le contexte dans lequel elle a été formulée ;
- le nombre de sources indépendantes qui la confirment.

Si aucune conclusion fiable ne peut être obtenue, le système doit afficher clairement le désaccord au lieu d'inventer une réponse définitive.

## 8. Traçabilité de la réponse


Chaque réponse devrait permettre de comprendre :


- quelles sources ont été utilisées ;
- quels passages du RAG ont été sélectionnés ;
- quels modèles ont participé ;
- quelles conclusions chaque modèle a proposées ;
- quelles contradictions ont été trouvées ;
- comment la synthèse finale a été obtenue ;
- quel est le niveau de confiance final.

Cette traçabilité est essentielle pour l'audit et pour la lutte contre les hallucinations.

## 9. Structure générale envisagée

Le fonctionnement peut être résumé ainsi :





## 10. Finalité du système

La finalité est d'obtenir une réponse :

- plus fiable qu'une réponse produite par un seul modèle ;
- enrichie par plusieurs perspectives ;
- fondée prioritairement sur le RAG ;
- complétée par le réel et l'actualité du web ;
- accompagnée de sources ;
- capable de gérer les contradictions ;
- peu créative lorsque la précision est prioritaire ;
- auditable ;
- avec un risque d'hallucination fortement réduit.

Le principe central est donc :

Le RAG fournit la base fiable, plusieurs modèles produisent des analyses différentes, le web complète ou actualise les informations, puis un modèle supérieur réalise une méta-synthèse sourcée en distinguant les faits solides, les contradictions et les incertitudes.

**Évaluation de la cohérence : 4,5/5.**

La vision est très cohérente. Le point à verrouiller maintenant est la hiérarchie exacte :

quand déclencher le web, comment noter les sources et quel modèle possède le droit de valider ou de rejeter une affirmation.